



Analisis Komparatif Model IndoBERT dan IndoBERTweet untuk Klasifikasi Hatespeech dan Sarkasme pada Teks bahasa Indonesia

Nama Kelompok	Hungry-bert
Nomor Kelompok	3
Anggota Kelompok	Husein Sidharta Muhammad - 245150707111040
	Jose Putra Perdana Taneo - 235150200111047

1. Latar Belakang

Perkembangan pesat dalam bidang Natural Language Processing (NLP) dan Deep Learning telah membawa perubahan besar dalam cara komputer memahami bahasa manusia. Model-model berbasis transformator seperti BERT (Devlin et al., 2019) dan RoBERTa (Liu et al., 2019) berhasil mencapai akurasi tinggi dalam berbagai tugas linguistik. Namun, mayoritas riset tersebut masih terfokus pada bahasa-bahasa berdaya sumber tinggi seperti Bahasa Inggris, sementara bahasa dengan sumber daya terbatas seperti Bahasa Indonesia masih menghadapi keterbatasan signifikan (Cahyawijaya et al., 2021). Kondisi ini menjadi paradoks, mengingat penggunaan Bahasa Indonesia di ranah digital meningkat pesat—lebih dari 210 juta pengguna internet di Indonesia berinteraksi setiap hari melalui teks di media sosial, forum, dan platform berita (APJII, 2024). Tingginya data ini membuka peluang sekaligus tantangan untuk menghadirkan model NLP yang mampu memahami konteks dan ekspresi khas masyarakat Indonesia.

Dalam konteks sosial, kebutuhan akan sistem analisis teks otomatis semakin mendesak, terutama untuk menangani isu ujaran kebencian dan misinformasi yang marak di ruang digital. Konten berbahaya ini



dapat memicu polarisasi sosial dan mengancam keamanan digital (Saputri et al., 2020). Di sisi lain, ekspresi yang bersifat sarkastik juga menghadirkan tantangan tersendiri karena maknanya kerap tersembunyi di balik struktur kalimat yang positif secara literal namun negatif secara makna (Joshi et al., 2017). Jika model NLP gagal mengenali sarkasme, maka sistem analisis sentimen dan deteksi kebencian bisa menghasilkan interpretasi yang salah. Oleh karena itu, pengembangan solusi berbasis AI yang mampu memahami dua fenomena linguistik yang sangat berbeda ini menjadi kebutuhan penting, baik untuk moderasi konten maupun analisis sosial digital.

Menjawab kebutuhan tersebut, komunitas riset Indonesia telah mengembangkan model transformer berbahasa Indonesia seperti IndoBERT (Koto et al., 2020) dan IndoBERTweet (Koto et al., 2021). IndoBERT dilatih menggunakan korpus formal yang luas seperti berita dan dokumen publik, sedangkan IndoBERTweet dikembangkan secara spesifik dari data Twitter untuk memahami bahasa informal, singkatan, dan gaya percakapan khas media sosial. Perbedaan pada data pre-training ini menjadikan keduanya menarik untuk dibandingkan, terutama dalam menghadapi tugas klasifikasi teks dengan karakteristik yang sangat kontras, seperti ujaran kebencian yang eksplisit dan sarkasme yang implisit.

Namun, hingga saat ini, masih terdapat celah penelitian (research gap) yang signifikan dalam pemahaman empiris mengenai bagaimana jenis data pre-training dan domain bahasa memengaruhi performa model dalam konteks NLP Bahasa Indonesia. Sebagian besar studi terdahulu hanya mengevaluasi satu model terhadap satu tugas spesifik, tanpa mengeksplorasi secara sistematis perbedaan perilaku model lintas domain (Alfina et al., 2018; Davidov et al., 2010). Padahal, penelitian komparatif antara IndoBERT dan IndoBERTweet terhadap dua jenis teks yang menantang ini dapat memberikan wawasan penting mengenai



kemampuan model memahami konteks, leksikon, dan nuansa emosional dalam Bahasa Indonesia.

Berdasarkan hal tersebut, ide ini diusulkan untuk mengisi celah tersebut dengan membandingkan performa IndoBERT dan IndoBERTweet dalam dua tugas yang mewakili dua dimensi linguistik berbeda: ujaran kebencian yang berbasis leksikal dan sarkasme yang berbasis konteks. Analisis ini diharapkan dapat mengungkap sejauh mana spesialisasi model memengaruhi kemampuan generalisasi dan sensitivitas terhadap konteks dalam Bahasa Indonesia.

2. Tujuan

Tujuan utama dalam proyek ini adalah sebagai berikut:

- Membandingkan performa model IndoBERT dan IndoBERTweet dalam tugas klasifikasi teks Bahasa Indonesia pada dua domain yang berbeda, yaitu deteksi hate speech (ujaran kebencian) dan deteksi sarcasm (sarkasme).
- Menganalisis pengaruh karakteristik data pre-training dan domain teks terhadap kemampuan generalisasi dan sensitivitas konteks dari kedua model.
- Memberikan evaluasi empiris dan metrik komparatif untuk menilai keunggulan dan kelemahan relatif kedua model dalam menghadapi teks formal dan informal Bahasa Indonesia.

3. Dataset

Dalam proyek ini, digunakan dua jenis dataset yang berbeda, yakni hate speech dan sarcasm. Keduanya berbasis bahasa Indonesia dan diambil dari dua sumber yang berbeda pula. Alasan digunakannya dua dataset ini ialah sebagai pembanding dan eksperimen jika transformer BERT bekerja dengan dua karakter data yang berbeda.

a. Dataset Hate Speech



Sumber dataset: [Link dataset / repositori]

Deskripsi: Jumlah data, jenis data (teks, gambar, tabular), ukuran dataset.

Preprocessing: Penjelasan tahapan (cleaning, normalisasi, augmentasi, dsb.)

Contoh data: Bisa sertakan potongan tabel/gambar representatif.

b. Dataset Sarcasm

- Sumber dataset: [w1lwo/reddit_indonesia_sarcastic · Datasets at Hugging Face](https://w1lwo/reddit_indonesia_sarcastic-Datasets-at-Hugging-Face)

- Deskripsi:

Dataset ini merupakan kumpulan data tekstual yang bersumber dari komentar-komentar di berbagai subreddit Indonesia. Tujuan utama dari dataset ini adalah untuk tugas klasifikasi biner, yaitu mengidentifikasi apakah sebuah komentar bersifat sarkastik (label 1) atau non-sarkastik (label 0). Dataset ini tersedia dalam dua format utama: sebuah file mentah (raw) berisi lebih dari 2,5 juta komentar dengan distribusi kelas yang tidak seimbang, dan versi yang sudah dipisah dan diseimbangkan kembali (re-balanced) menjadi tiga file; train, validation, test.

Sebelumnya, telah dilakukan exploratory data analysis atau EDA untuk dataset raw. Temuan utama yang didapat ialah bahwa dataset raw ini sangat tidak seimbang, dengan detail seperti berikut. Terlihat bahwa kelas non-sarkastik sangat mendominasi bahkan mencapai 99%.

```
Distribusi Kelas:
label
0      2616335
1         3529
Name: count, dtype: int64

Persentase kelas 1 (Sarkastik): 0.13%
Persentase kelas 0 (Non-Sarkastik): 99.87%
```

Untuk itulah, pembuat dataset melakukan balancing data dan split menjadi train, validation, dan test.



DIKTISAINTEK
BERDAMPAK

Split	#sarcastic	#non sarcastic	#total
train	2470	7411	9881
test	706	2118	2824
validation	353	1058	1411
Total (balanced)	3529	10587	14116
Total (unbalanced)	3529	2616335	2619864

Dalam proyek ini, dataset yang digunakan adalah data hasil balanced, yakni langsung ketiga file tersebut. Pendekatan ini dipilih mengingat ukuran dataset raw yang terlalu besar untuk sumber daya yang kami miliki, sehingga dapat menghambat proses training. Sementara data hasil balancing dinilai masih cukup rasional untuk sumber daya tanpa banyak menghilangkan data penting.

Berikut adalah dokumentasi EDA untuk dataset raw:

https://docs.google.com/document/d/1sJ9r_6ZrPASijN3KJI2HudXLRcprkho3VFg6JluIQ/edit?usp=sharing

- Preprocessing:
 1. Loading Data dan Transformasi

Tahap pertama adalah memuat data dari repositori GitHub. Setelah itu dilihat isi file JSON untuk dianalisis. Ternyata terdapat bentuk struktur yang tidak sesuai, dimana strukturnya memuat 1 baris x N kolom.

Out[2]:

	0	1	2	3	4	5
0	{'author': 'liberal_minangnese', 'created_utc':...	{'author': 'IceF14re', 'created_utc': 15928267...	{'author': 'Winter_Anxiety', 'created_utc': 16...	{'author': 'spicyrendang', 'created_utc': 1617...	{'author': 'Qolapse', 'created_utc': 166057163...	{'author': 'curuya', 'created_utc': 158487652...

1 rows x 9881 columns

Oleh karena itu, perlu dilakukan transformasi untuk mengubahnya menjadi format tabel yang benar (banyak baris x beberapa kolom), menghasilkan DataFrame yang siap diolah lebih lanjut.

	author	created_utc	score	permalink	subreddit	body	lar
0	liberal_minangnese	1.609055e+09	7	/r/indonesia/comments/kkj01g/mengapa_sentimen...	indonesia	Lo bilang chinese playing victim tapi lo gasad...	id
1	IceF14re	1.592827e+09	140	/r/indonesia/comments/hdq6gx/terjemahannya_nge...	indonesia	Kadang-kadang sampe aku mikir "kayaknya buku g...	id
2	Winter_Anxiety	1.669217e+09	1	/r/indonesia/comments/z2mmfu/this_fucking_guy_...	indonesia	Bukanya berduka mih buat konspirasi sendiri	id
3	spicyrendang	1.617185e+09	6	/r/indonesia/comments/mgkqyi/31_march_2021_dai...	indonesia	Atta Halilintar pamer di youtube; "Dasar pamer...	id
4	Qolapse	1.660572e+09	2	/r/indonesia/comments/woxxfv/bersama_kita_bisa...	indonesia	Pasti lokasinya di kalimantan	id

2. Persiapan sumber daya

Selanjutnya, adalah tahap mempersiapkan dua alat bantu utama untuk pembersihan teks. Yang pertama adalah pembuatan daftar stopwords standar Bahasa Indonesia dari library NLTK. Kemudian ditambah dengan daftar stopwords custom yang relevan untuk bahasa percakapan di media sosial (contoh: yg, gak, sih, dong, wkwk). Yang kedua adalah pembuatan kamus (slang_dict) untuk menormalisasi kata-kata slang atau singkatan umum ke dalam bentuk bakunya (contoh: bgt diubah menjadi banget, klo menjadi kalau).

3. Fungsi preprocessing (tipe data, penghilangan tag, pembersihan dasar)



Tahap pertama yang dilakukan ialah penanganan Tipe Data. Tahap ini berfungsi untuk menangani input yang tidak konsisten, seperti list atau dict, dan mengubahnya menjadi format string yang dapat diolah. Tahap kedua adalah pencegahan Data Leakage dengan menghapus tag /s di akhir kalimat pada data berlabel sarkas. Ini adalah yang penting untuk memastikan model tidak curang.

Tahap ketiga adalah pembersihan dasar. Pada tahap ini dilakukan pembersihan yaitu mengubah semua teks menjadi huruf kecil (lowercasing), menghapus URL dan user mentions (u/...), menghapus karakter-karakter yang tidak relevan (selain huruf, angka, dan tanda baca penting), dan menormalisasi spasi berlebih.

4. Pembuatan empat skenario eksperimen

Khusus dataset ini, digunakan empat skenario eksperimen yang berbeda. Hal ini dilakukan berdasarkan bagian remove stopwords dan normalisasi. Kami ingin bereksperimen apakah penggunaan kedua preprocessing ini bisa mempengaruhi hasil model, khususnya pada dataset berbasis sarkasme. Proses ini dijalankan menggunakan parameter boolean (remove_stopwords dan normalize_slang).

Stopwords + Normalisasi: Versi paling bersih, dimana slang dinormalisasi dan stopwords dihapus.

Stopwords + Tanpa Normalisasi: Hanya menghapus stopwords tanpa mengubah slang.

Tanpa Stopwords + Normalisasi: Hanya menormalisasi slang tanpa menghapus stopwords.

Tanpa Stopwords + Tanpa Normalisasi: Versi baseline yang hanya melalui pembersihan dasar.

5. Penyimpanan hasil

Tahap terakhir adalah menyimpan DataFrame yang berisi empat variasi teks bersih ke dalam format Parquet. Dibuat kolom-kolom baru (label dan empat kolom teks baru), dan menghasilkan tiga file output (train_processed.parquet, val_processed.parquet, test_processed.parquet) sehingga lebih cepat dan siap digunakan untuk tahap pemodelan.


# label	text_sw_norm	text_sw_nonorm	text_nosw_norm	text_nosw_nonorm
	2821 unique values	2821 unique values	2824 unique values	2824 unique values
0	penduduknya padat masuk kampung, jalanin prokes seketat kota besar. kota dijaga karantinanya.	penduduknya padat masuk kampung, jalanin prokes seketat kota besar. kota dijaga karantinanya.	kalo penduduknya tidak padat dan tidak banyak yang keluar masuk kampung, bisa jadi memang tidak per...	kalo penduduknya nggak padat dan gak banyak yg keluar masuk kampung, bisa jadi memang gak perlu jalan...
1	laiknya jerman abad 20!	laiknya jerman abad 20!	kita harus menjadi layaknya jerman abad 20!	kita harus menjadi layaknya jerman abad 20!
0	mrt jakarta ikutin budaya jepang kyknya menaikan standar normalnya dunia konstruksi hard labornya. p...	mrt jakarta ikutin budaya jepang kyknya menaikan standar normalnya dunia konstruksi hard labornya. p...	makanya mrt jakarta karena ikutin budaya jepang kan kyknya menaikan standar normalnya seperti aoa du...	makanya mrt jakarta krn ikutin budaya jepang kan kyknya menaikan standar normalnya seperti aoa dunia...

4. Metodologi & Eksperimen

- Arsitektur Model:

BERT-base

Proyek ini menggunakan dua model deep learning berbasis arsitektur Transformer, yaitu IndoBERT dan IndoBERTweet. Arsitektur Transformer memanfaatkan mekanisme self-attention untuk mengukur pentingnya setiap token dalam konteks sekuens, sehingga mampu menangkap hubungan semantik jangka panjang dalam teks. Kedua model merupakan varian Bidirectional Encoder Representations from Transformers (BERT; Devlin et al., 2019) yang telah di-pre-train secara khusus untuk Bahasa Indonesia.



Secara umum, arsitektur Transformer Encoder yang digunakan dalam BERT terdiri dari beberapa komponen utama. Yang pertama adalah Input Embedding Layer. Setiap token teks diubah menjadi vektor berdimensi tetap (768 untuk versi base). Embedding ini merupakan gabungan dari tiga komponen:

- (a) Token Embedding,
- (b) Segment Embedding (untuk membedakan kalimat A dan B dalam tugas NSP), dan
- (c) Positional Embedding (agar urutan kata tetap terjaga).

Yang kedua adalah Multi-Head Self-Attention. Setiap encoder block memiliki mekanisme multi-head attention yang membagi ruang representasi menjadi beberapa attention heads. Tiap kepala mempelajari hubungan semantik yang berbeda antar-token. Proses ini dapat diformulasikan dengan fungsi:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$



di mana Q, K, dan V adalah proyeksi dari embedding token ke ruang query, key, dan value.

Komponen ketiga adalah Feed-Forward Network (FFN). Setelah self-attention, hasilnya dilewatkan melalui lapisan jaringan saraf dua tingkat (fully connected layer) dengan fungsi aktivasi GELU (Gaussian Error Linear Unit). FFN ini bekerja identik untuk setiap token, tetapi parameter berbagi di seluruh posisi.

Komponen terakhir adalah Residual Connections & Layer Normalization. Setiap blok encoder dilengkapi dengan residual connections yang membantu aliran gradien dan layer normalization untuk stabilitas pelatihan.

IndoBERT

IndoBERT dilatih menggunakan Indo4B corpus, sebuah korpus besar berisi ±4 miliar kata (250GB teks mentah). Dataset ini berasal dari sumber formal seperti berita daring, Wikipedia, blog, dan media sosial. Model IndoBERT di-pretrain menggunakan dua unsupervised tasks yang sama seperti BERT asli:

- Masked Language Modeling (MLM):

15% token dalam kalimat diacak untuk di-mask dan model ditugaskan memprediksi token asli. Tujuannya adalah agar model memahami konteks bidireksional antar-token.

- Next Sentence Prediction (NSP):

Model mempelajari hubungan antar dua kalimat berturut-turut untuk menangkap keterkaitan semantik antar-kalimat.

Pelatihan dilakukan selama 1 juta langkah dengan batch size besar (256), sequence length 512, dan learning rate $1e-4$ menggunakan Adam optimizer. Hasilnya, model memiliki pemahaman semantik yang baik terhadap struktur kalimat formal Bahasa Indonesia.



IndoBERTweet

IndoBERTweet dilatih dari awal menggunakan sekitar 700 juta token dari 26 juta tweet Bahasa Indonesia. Korpus ini dikumpulkan dari Twitter API dengan filter lang:id, serta melalui proses pembersihan untuk menghapus retweets, URLs, dan duplicated tweets. Berbeda dengan IndoBERT, IndoBERTweet menggunakan case-insensitive training (uncased) karena teks media sosial sering tidak konsisten dalam kapitalisasi. Proses pre-training juga menggunakan dua tugas yang sama (MLM + NSP), tetapi tokenisasi dan vocabulary dioptimalkan untuk slang dan struktur informal khas media sosial.

Model ini memperlihatkan robustness lebih baik pada domain noisy text, yang telah dibuktikan pada benchmark IndoNLU dan IndoNLG.

Perbedaan mendasar antara kedua model ini terletak pada:

- Domain pre-training: formal vs. informal.
- Tokenization: WordPiece vs. BPE yang disesuaikan untuk media sosial.
- Casing dan noise tolerance: IndoBERT bersifat cased, IndoBERTweet uncased.

Perbedaan tersebut akan menghasilkan analisis mendalam mengenai bagaimana variasi domain data pre-training memengaruhi kemampuan model memahami konteks eksplisit (hate speech) dan implisit (sarcasm) dalam Bahasa Indonesia.

- **Baseline:**

Model IndoBERT digunakan sebagai baseline, sedangkan IndoBERTweet menjadi model pembandingan. Pendekatan ini akan menghasilkan analisis terhadap pengaruh pre-training (formal vs. informal) pada performa model. Perbandingan dilakukan berdasarkan dua metrik utama, yaitu F1-Score (yang menyeimbangkan precision dan recall) dan Matthews Correlation



Coefficient (MCC), yang lebih robust terhadap ketidakseimbangan kelas.

- Langkah Eksperimen:

Eksperimen dilakukan melalui beberapa tahap, yakni:

- a. Preprocessing

Tahap pertama adalah persiapan data. Dataset Hatespeech dan Sarcasm diproses melalui rangkaian/pipeline pembersihan standar untuk NLP. Khusus untuk dataset Sarcasm, dihasilkan empat variasi dataset untuk setiap tugas, yang dirancang untuk menguji dampak dari langkah preprocessing yang berbeda:

- Tanpa Stopword Removal + Tanpa Normalisasi Slang (Baseline)
 - Dengan Stopword Removal + Tanpa Normalisasi Slang
 - Tanpa Stopword Removal + Dengan Normalisasi Slang
 - Dengan Stopword Removal + Dengan Normalisasi Slang

- b. Training & Hyperparameter

Model IndoBERT dilatih dan dievaluasi pada kedua dataset (Hatespeech dan Sarcasm) dengan learning rate $2e-15$ dan epoch = 3. Sementara metric yang digunakan untuk best model adalah F1-score.

- c. Eksperimen Freeze Layers

Untuk mengeksplorasi lebih lanjut, dilakukan eksperimen tambahan dimana 7 layer pertama (dari total 12 layer) dari model IndoBERT dan IndoBERTweet "dibekukan" (frozen). Ini berarti hanya layer 8 hingga 12 yang dilatih ulang. Eksperimen ini bertujuan untuk melihat apakah hanya dengan melatih layer-layer akhir yang lebih kontekstual sudah cukup untuk mencapai performa tinggi, sekaligus berpotensi mengurangi overfitting dan mempercepat training.

- d. Perbandingan Hasil dan Analisis



Tahap terakhir adalah mengumpulkan semua hasil evaluasi dari setiap eksperimen. Performa model dibandingkan berdasarkan metrik utama, yaitu F1-Score dan Matthews Correlation Coefficient (MCC). Analisis mendalam kemudian dilakukan untuk mengetahui model mana yang berkinerja lebih baik, strategi preprocessing mana yang paling efektif, dan bagaimana dampak dari teknik freeze layers terhadap hasil akhir.

5. Hasil & Evaluasi

a. Metrik Evaluasi

Untuk mengukur performa model, terutama pada tugas klasifikasi yang memiliki distribusi kelas tidak seimbang (dataset sarcasm), proyek ini menggunakan dua metrik utama:

- F1-Score: Adalah rata-rata harmonik dari Precision dan Recall. Metrik ini memberikan gambaran yang seimbang antara kemampuan model untuk tidak salah melabeli kelas positif (Precision) dan kemampuannya untuk menemukan semua sampel positif yang ada (Recall). Skor berkisar dari 0 (terburuk) hingga 1 (terbaik).
- Matthews Correlation Coefficient (MCC): Adalah salah satu metrik paling informatif untuk klasifikasi biner. MCC menghitung koefisien korelasi antara prediksi dan label aktual, dengan mempertimbangkan keempat kategori dalam confusion matrix (TP, TN, FP, FN) secara seimbang. Skornya berkisar dari -1 (prediksi terbalik sempurna), 0 (prediksi acak), hingga +1 (prediksi sempurna).

b. Hasil Eksperimen Secara Umum

Model	Metode Pelatihan	Sarcasm Dataset		Hate speech Dataset
		F1-Score (Weighted)	MCC	F1-Score (Weighted)
IndoBERT	Full	0.7975	0.4545	0.8832
IndoBERTweet	Fine-Tuning	0.795	0.451	0.7783
IndoBERT	Freeze Layer	0.805	0.4692	0.8593
IndoBERTweet	1-7	0.79	0.4263	0.7146

Dataset sarcasm diukur melalui dua metrik, F1-Score dan MCC, dikarenakan kelas datanya yang sangat tidak seimbang. Sementara hate speech hanya menggunakan metrik utama yaitu F1-Score.

Untuk dataset sarcasm, performa paling tinggi berada pada model IndoBERT dengan metode pelatihan Freeze Layer 1-7, dimana F1-Score bernilai 0.805 dan MCC bernilai 0.4692. Sedangkan untuk dataset hate speech, performa paling tinggi didapatkan oleh IndoBERT dengan nilai F1-Score adalah 0.8832.

Dari segi model, IndoBERT memperoleh performa paling tinggi ketika dihadapkan pada dataset hate speech dengan metode pelatihan full fine-tuning. Sementara IndoBERTweet memperoleh performa paling tinggi untuk dataset hatespeech dengan metode pelatihan full fine-tuning.

Dari segi model pelatihan, terlihat efek terhadap setiap model dan dataset sangat beragam. Pada dataset sarcasm, IndoBERT mengalami kenaikan performa ketika metode pelatihan beralih ke freeze layer. Sementara IndoBERTweet justru mengalami penurunan ketika diberlakukan freeze layer. Pada dataset hate speech, IndoBERT dan IndoBERTweet justru kompak mengalami penurunan saat freeze layer.

Secara umum, model IndoBERT mendominasi hasil performa yang lebih baik daripada IndoBERTweet, berlaku untuk semua dataset.


c. Hasil Eksperimen Dataset Sarcasm

Model	Skenario Preprocess	F1-Score	MCC
IndoBERT (Full Fine-Tuning)	SW + Norm	0.7762	0.3917
	SW + NoNorm	0.7758	0.3919
	NoSW + Norm	0.7928	0.4357
	NoSW + NoNorm	0.7909	0.4313
IndoBERTweet (Full Fine-Tuning)	SW + Norm	0.7869	0.4216
	SW + NoNorm	0.783	0.4097
	NoSW + Norm	0.8047	0.4725
	NoSW + NoNorm	0.8112	0.4876

Pada dataset sarcasm, diberlakukan seleksi terhadap 4 variasi preprocessing yang berbeda terlebih dahulu. Setelah itu hasil yang terbaik dijadikan perbandingan ke dataset lain. Pada IndoBERT, performa terbaik diraih oleh data preprocessing yang tidak diberi stopwords (NoSW) tetapi diberlakukan normalisasi (Norm). Sementara pada IndoBERTweet, performa terbaik terjadi ketika data tidak diberlakukan stopwords (NoSW) dan tidak diberi normalisasi juga (NoNorm). Maka, kedua hasil terbaik dari masing-masing model inilah yang akan dievaluasi lebih lanjut. Namun, dari hasil eksperimen 4 variasi ini bisa dijadikan bahan analisis lebih lanjut.

Hasil IndoBERT Full Fine-Tuning (NoSW+Norm):

	precision	recall	f1-score	support
Non-Sarkastik	0.86	0.88	0.87	2118
Sarkastik	0.61	0.55	0.58	706
accuracy			0.80	2824
macro avg	0.73	0.72	0.73	2824
weighted avg	0.79	0.80	0.80	2824
Matthews Correlation Coefficient (MCC) Final: 0.4515				



Hasil IndoBERT Freeze Layer (NoSW+Norm):


	precision	recall	f1-score	support
Non-Sarkastik	0.85	0.91	0.88	2118
Sarkastik	0.65	0.53	0.58	706
accuracy			0.81	2824
macro avg	0.75	0.72	0.73	2824
weighted avg	0.80	0.81	0.81	2824

Matthews Correlation Coefficient (MCC): 0.4692



DIKTISAINTEK
BERDAMPAK


Confusion Matrix Freeze Layer - indobert_freeze_7



Hasil IndoBERTweet Full Fine-Tuning (NoSW+NoNorm):

	precision	recall	f1-score	support
Non-Sarkastik	0.85	0.90	0.87	2118
Sarkastik	0.63	0.52	0.57	706
accuracy			0.81	2824
macro avg	0.74	0.71	0.72	2824
weighted avg	0.80	0.81	0.80	2824

Matthews Correlation Coefficient (MCC) Final: 0.4510




Hasil IndoBERTweet Freeze Layer (NoSW+NoNorm):

	precision	recall	f1-score	support
Non-Sarkastik	0.84	0.91	0.87	2118
Sarkastik	0.63	0.48	0.55	706
accuracy			0.80	2824
macro avg	0.73	0.69	0.71	2824
weighted avg	0.79	0.80	0.79	2824

Matthews Correlation Coefficient (MCC): 0.4263



Confusion Matrix Freeze Layer - indobertweet_freeze_7



d. Hasil Eksperimen Dataset Hate Speech


Pada dataset hate speech tidak diberlakukan variasi preprocess, sehingga hasilnya hanya 1 dan dapat langsung dijadikan bahan evaluasi. Berikut adalah hasilnya visualisasi confusion matrixnya.

Hasil IndoBERT Full Fine-Tuning:

LABORATORY




Confusion Matrix - IndoBERT Hatespeech Detection



Hasil IndoBERT Freeze Layer:

Confusion Matrix - IndoBERT Hatespeech Detection






DIKTISAINTEK
BERDAMPAK


Hasil IndoBERTweet Full Fine-Tuning:

Confusion Matrix - BertTweet Hatespeech Detection



Hasil IndoBERTweet Freeze Layer:

Confusion Matrix - BertTweet Hatespeech Detection





6. Diskusi

a. Analisis Hasil Dataset Sarcasm

IndoBERT Full Fine-Tune

Berdasarkan hasil, model IndoBERT dengan full fine-tuning menunjukkan performa yang baik. Dengan F1-Score mencapai 0.7975 dan MCC sebesar 0.4545, model ini menunjukkan kemampuan yang kuat dalam membedakan antara komentar sarkastik dan non-sarkastik, spesifiknya pada kelas mayoritas (non-sarkastik). Skor MCC yang berada di angka rendah, yang menandakan adanya model memiliki performa yang lemah pada kelas minoritas (sarkastik).

Analisis pada confusion matrix memberikan gambaran yang lebih detail. Kekuatan model ini terletak pada kemampuannya untuk secara akurat mengidentifikasi kelas mayoritas (Non-Sarkastik), dimana ia membuat 247 kesalahan (False Positives) dari total 2118 data. Namun, tantangan utamanya ada pada pendeteksian kelas minoritas (Sarkastik). Terbukti, model ini masih melewatkan 316 dari 706 komentar sarkastik (False Negatives).

IndoBERT Freeze Layer

Berdasarkan hasil yang disajikan, penerapan teknik freeze layer pada IndoBERT dapat menghasilkan model dengan performa terbaik di antara semua eksperimen yang dilakukan pada dataset sarkasme. Model ini berhasil mencapai F1-Score tertinggi sebesar 0.805 dan MCC sebesar 0.4692. Peningkatan performa dibandingkan dengan versi full fine-tuning ini mendukung hipotesis bahwa pembekuan layer-layer awal berfungsi sebagai teknik regularisasi yang efektif, mencegah model dari overfitting pada data latih. Namun, yang menjadi titik kelemahan masih sama, yaitu pada nilai MCC yang rendah. Ini masih menjadi pertanda model masih kesulitan mendeteksi kelas minoritas (sarkasme).



Dalam confusion matrix, model ini menunjukkan keseimbangan yang sedikit lebih baik dalam membuat kesalahan. Jumlah kesalahan dalam melabeli non-sarkasme sebagai sarkasme (False Positives) turun menjadi 199 kasus. Namun, jumlah komentar sarkasme yang terlewat (False Negatives) malah naik menjadi 332 kasus. Ini menunjukkan bahwa dengan hanya melatih layer-layer akhir yang lebih kontekstual, IndoBERT mampu membentuk pemahaman yang lebih baik dalam mengklasifikasikan non-sarkasme, tetapi tetap kesulitan mendeteksi sarkasme.

IndoBERTweet Full Fine-Tune

Berdasarkan hasil percobaan, model IndoBERTweet dengan full fine-tuning menunjukkan performa yang baik secara keseluruhan, tetapi punya satu kelemahan yang jelas. Metrik F1-score yang mencapai 0.795 terlihat sangat baik dan menandakan bahwa model memiliki keseimbangan yang baik antara precision dan recall secara rata-rata. Namun, skor MCC yang lebih rendah di 0.451 mengindikasikan bahwa performa model tidak seimbang di kedua kelas dan performanya tidak sesempurna yang ditampilkan oleh F1-score.

Dalam confusion matrix, model ini baik dalam mengidentifikasi kelas mayoritas (Non-Sarkastik), dengan 211 kesalahan dari 2118 data. Namun, kelemahan utamanya terletak pada pendeteksian kelas minoritas (Sarkastik). Model gagal mendeteksi 339 dari 706 komentar sarkastik (False Negatives). Ini menunjukkan bahwa meskipun modelnya bagus, ia memiliki kecenderungan untuk menebak "Non-Sarkastik" ketika tidak yakin, sehingga banyak sarkasme yang lolos dari deteksi.

IndoBERTweet Freeze Layer

Berdasarkan hasil, penerapan teknik freeze layer pada IndoBERTweet menunjukkan penurunan performa yang terlihat jelas dibandingkan dengan metode full fine-tuning. Skor F1-score turun



menjadi 0.790 dan MCC juga menurun ke 0.4263. Penurunan ini menunjukkan bahwa membekukan 7 layer pertama telah menurunkan kemampuan model untuk beradaptasi dengan tugas deteksi sarkasme yang spesifik ini.

Pada confusion matrix, terlihat adanya perubahan perilaku model. Jumlah sarkasme yang terlewat (False Negatives) sedikit memburuk menjadi 366 kasus. Sementara hasil klasifikasi non-sarkasme (False Positives) yang membaik menjadi 200 kasus. Ini menunjukkan bahwa dengan layer yang dibekukan, model menjadi kurang baik dan lebih cenderung salah menebak Sarkas menjadi Non-Sarkas, yang pada akhirnya menurunkan kualitas prediksi secara keseluruhan, sebagaimana terlihat oleh skor MCC yang lebih rendah.

Dampak Preprocessing

Salah satu hasil yang paling signifikan dari eksperimen awal adalah bahwa strategi preprocessing yang terbaik ternyata bergantung pada model yang digunakan. Dalam kata lain, setiap model punya strategi preprocessing yang cocok.

Untuk kedua model, IndoBERT dan IndoBERTweet, performa terbaik secara konsisten diraih ketika stopwords tidak dihapus (NoSW). Ini adalah bukti yang mendukung pendapat bahwa dalam sarkasme, stopwords bukan sekadar kata pengisi yang tidak penting. Kata-kata kecil dalam percakapan seperti sih, deh, kok, kan, ya, yang termasuk dalam daftar stopwords, ternyata bisa membawa parameter dalam menilai konteks sarkasme. Jika stopwords dihapus, meskipun membuat teks lebih bersih secara teks, justru menghilangkan sebagian informasi penting dari kalimat, sehingga mempersulit model untuk mendeteksi makna tersembunyi di balik teks.

Hasil temuan lain yang menarik adalah bagaimana normalisasi slang memberikan dampak yang berlawanan pada kedua model. Performa IndoBERT meningkat ketika slang dinormalisasi (text_nosw_norm). Ini dapat dijelaskan oleh adanya perbedaan domain antara data pre-training IndoBERT (data formal dan umum



dari Indo4B) dengan dataset sarkasme yang sangat informal. Dengan menormalisasi slang (bgt → banget, ga → tidak), kita bisa menerjemahkan bahasa Reddit yang gaul ke dalam bentuk yang lebih standar dan lebih mudah dipahami oleh model IndoBERT. Sebaliknya, IndoBERTweet bekerja lebih baik tanpa normalisasi slang (text_nosw_nonorm). Ini karena IndoBERTweet telah di-pretrain pada jutaan tweet dan kemungkinan besar sudah mempelajari pola dan konteks yang terkait langsung dengan kata-kata slang seperti bgt atau ga. Jika kita melakukan normalisasi, justru bisa menghilangkan kata atau informasi yang spesifik yang telah dipelajari oleh model dari bentuk aslinya.

Keunggulan IndoBERT dibanding IndoBERTweet Pada Sarcasm

Ini adalah salah satu temuan yang cukup kontradiktif dari penelitian ini. Awalnya, kami berpendapat bahwa model yang dilatih pada data media sosial (IndoBERTtweet) akan lebih unggul. Namun, hasil eksperimen secara konsisten menunjukkan bahwa IndoBERT memiliki performa yang sedikit lebih baik pada kasus deteksi sarkasme. Menurut kami sendiri beberapa faktor yang berkaitan dengan sifat sarkasme itu sendiri dan keragaman data pre-training.

Kesalahan asumsi kami adalah bahwa karena data Reddit bersifat informal, maka model yang paling ahli dalam bahasa informal akan otomatis menang. Namun, sarkasme juga adalah fenomena bahasa dan literasi yang kompleks. Ia tidak hanya bergantung pada penggunaan slang atau singkatan, tetapi lebih menitikberatkan pada pembalikan makna secara kontekstual, ironi, dan disesuaikan dengan konteks di dunia nyata.

Untuk mendeteksi sarkasme dalam kalimat "Wah, idenya jenius sekali" (yang sebenarnya menyindir), model tidak hanya perlu tahu arti kata "jenius", tetapi juga harus bisa merasakan bahwa penggunaan kata tersebut dalam konteks yang diberikan terasa berlebihan. Kemampuan ini perlu pemahaman semantik dan penalaran yang lebih mendalam.



Keunggulan IndoBERT lainnya adalah bahwa model ini dilatih pada korpus Indo4B yang sangat masif dan beragam, mencakup berita, artikel Wikipedia, literatur, dan juga media sosial. Data yang beragam ini memberikan IndoBERT fondasi pemahaman Bahasa Indonesia yang lebih luas dan mendalam. Ia tidak hanya belajar bahasa percakapan, tetapi juga struktur kalimat yang lebih formal, hubungan sebab-akibat yang logis, dan pengetahuan umum yang lebih luas.

Fondasi yang kuat inilah yang kemungkinan besar membuat model lebih unggul dalam mendeteksi konteks dan makna, yang menjadi titik berat dari sarkasme. Sementara IndoBERTweet sangat ahli dalam menangani noise dan pola spesifik Twitter. IndoBERT mungkin punya pemahaman yang lebih luas mengenai apa itu makna dan konteks, sehingga ia lebih sensitif ketika menemukan kalimat yang maknanya tidak normal atau ironis.

Selanjutnya adalah perbandingan antara data train twitter dengan teks reddit. Meskipun keduanya sama-sama informal, gaya bahasa di Reddit pasti tidak 100% sama dengan Twitter. Reddit bisanya berisi diskusi yang lebih panjang dan terstruktur, sementara Twitter sangat didominasi oleh teks yang sangat pendek dan cepat. Ada kemungkinan bahwa keragaman data pre-training IndoBERT ternyata lebih cocok untuk menangani variasi gaya bahasa di Reddit dibandingkan dengan data pre-training IndoBERTweet.

Perbedaan Metrik F1-Score dan MCC

Berdasarkan hasil percobaan di dataset sarcasm, semua model mencapai F1-Score yang relatif tinggi. Meski begitu, skor MCC-nya jauh lebih rendah (sekitar 0.40). Perbedaan ini menunjukkan kelemahan signifikan dalam performa model. F1-Score yang tinggi sebagian besar adalah hasil kemampuan model untuk secara akurat mengklasifikasikan kelas mayoritas, yaitu Non-Sarkastik. Sementara MCC yang Rendah adalah penanda yang menunjukkan bahwa model



masih sangat kesulitan dalam mendeteksi kelas minoritas, yaitu Sarkastik.

Bukti dari masalah ini terlihat pada confusion matrix. Dari total 706 komentar sarkastik, model gagal mendeteksi 300 di antaranya (42.5%), dan salah melabelinya sebagai non-sarkastik (False Negatives). Ini menunjukkan bahwa model cenderung menebak kelas mayoritas ketika tidak yakin, yang mengakibatkan banyak kasus sarkasme terlewat. MCC dapat menunjukkan ketidakseimbangan performa ini, sementara F1-Score kurang menunjukkan sisi ini.

b. Analisis Hasil Dataset Hate Speech

IndoBERT Full Fine-Tune

Berdasarkan hasil, model IndoBERT dengan full fine-tuning menunjukkan performa yang kuat dan efektif pada tugas deteksi ujaran kebencian. Dengan pencapaian F1-Score sebesar 0.8832 pada test set, model ini membuktikan bahwa ia punya keseimbangan baik antara presisi dan recall, yang didukung pula oleh akurasi keseluruhan yang mencapai 90.16%. Ini menandakan bahwa model dasar IndoBERT sangat kompeten dalam mempelajari pola-pola yang ada pada dataset ujaran kebencian.

Analisis lebih dalam pada confusion matrix mengungkap perilaku model yang seimbang dalam membuat kesalahan. Terlihat bahwa jumlah kasus ujaran kebencian yang terlewat (False Negatives) adalah 83, sementara jumlah kasus non-ujaran kebencian yang salah diklasifikasikan (False Positives) adalah 79. Angka-angka yang hampir setara ini menunjukkan bahwa model tidak memiliki bias yang signifikan terhadap salah satu kelas. Performa yang seimbang ini mengindikasikan bahwa fitur-fitur dalam dataset ujaran kebencian cukup jelas bagi model untuk dapat membedakan kedua kelas dengan tingkat keyakinan yang sebanding.

IndoBERT Freeze Layer



Berdasarkan hasil, penerapan teknik freeze layer pada model IndoBERT untuk tugas deteksi ujaran kebencian mengakibatkan penurunan performa yang nyata. F1-Score turun dari 0.8833 (pada full fine-tuning) menjadi 0.8594, dan akurasi juga menurun menjadi 88.10%. Penurunan ini mengindikasikan bahwa membekukan 7 layer pertama justru merugikan kemampuan model dalam mengenali pola-pola spesifik pada dataset Hatespeech.

Dibandingkan dengan versi full fine-tuning, model dengan freeze layer membuat lebih banyak kesalahan di kedua sisi: jumlah kasus ujaran kebencian yang terlewat (False Negatives) meningkat menjadi 97, dan jumlah kasus non-ujaran kebencian yang salah diklasifikasikan (False Positives) juga meningkat menjadi 99. Hal ini bisa diakibatkan karena deteksi ujaran kebencian sangat bergantung pada pemahaman leksikal (kata-kata kunci). Dengan membekukan layer-layer awal yang fundamental, model dapat kesulitan menyesuaikan pemahamannya terhadap kata-kata kasar dan frasa kebencian yang penting untuk tugas ini.

IndoBERTweet Full Fine-Tune

Berdasarkan hasil, model IndoBERTweet dengan full fine-tuning menunjukkan performa yang secara signifikan lebih rendah dibandingkan dengan model IndoBERT. Dengan F1-Score yang hanya mencapai 0.7783, model ini lebih lemah untuk mengklasifikasikan dataset Hatespeech. Hasil ini cukup kontradiktif, mengingat IndoBERTweet di-pretrain pada data media sosial yang seharusnya lebih relevan dengan domain ujaran kebencian.

Pada confusion matrix terlihat bahwa angka False Negatives tinggi. Terbukti, model ini melewatkan 185 kasus ujaran kebencian yang sebenarnya dan salah mengklasifikasikannya sebagai non-ujaran kebencian. Jumlah kesalahan ini jauh lebih tinggi daripada model IndoBERT, yang secara langsung menyebabkan skor recall (0.7341) dan F1-Score menjadi rendah. Ini menunjukkan bahwa meskipun IndoBERTweet adalah spesialis bahasa informal,



pemahaman konteksnya mungkin kurang sesuai dengan tipe bahasa ujaran kebencian, dan membuat model cenderung ragu-ragu dan gagal mengidentifikasi banyak kasus.

IndoBERTweet Freeze Layer

Berdasarkan hasil, penerapan teknik freeze layer pada IndoBERTweet mengakibatkan penurunan performa yang drastis, menjadikannya model dengan kinerja terendah di antara semua eksperimen pada dataset Hatespeech, bahkan Sarcasm pula. F1-Score turun secara signifikan menjadi 0.7146, dan akurasi turun ke 77.35%. Ini menunjukkan dengan jelas bahwa membekukan layer-layer awal sangat merugikan kemampuan IndoBERTweet dalam tugas ini, lebih parah daripada dampaknya pada IndoBERT.

Jumlah kasus ujaran kebencian yang terlewat (False Negatives) menurun menjadi 229, dan model ini secara keliru melabeli 144 kasus non-ujaran kebencian sebagai ujaran kebencian, meningkat cukup banyak dari versi full fine-tuning. Ini menunjukkan bahwa dengan layer yang dibekukan, model menjadi terlalu sensitif dan tidak lagi dapat membedakan dengan cermat, yang pada akhirnya menghancurkan keseimbangan presisi dan recall, sehingga menghasilkan skor F1 yang rendah.

Keunggulan IndoBERT pada Dataset Hate Speech

Salah satu temuan dari eksperimen pada dataset ujaran kebencian adalah keunggulan performa model IndoBERT dibandingkan IndoBERTweet. Hasil ini cukup kontradiktif, mengingat IndoBERTweet secara teoretis lebih terlatih untuk memahami bahasa di media sosial. Namun, ada beberapa alasan kuat mengapa IndoBERT justru bisa mengalahkan IndoBERTweet dalam tugas spesifik ini.

Alasan utamanya terletak pada sifat dari teks hate speech itu sendiri dan keberagaman data pelatihan masing-masing model. Deteksi ujaran kebencian seringkali lebih bergantung pada



pengenalan bahasa, seperti pengenalan kata-kata kunci yang kasar, merendahkan, atau agresif. Artinya pengenalan bahasa ini lebih cenderung lebih penting daripada pemahaman konteks yang sangat mendalam seperti pada sarkasme. Karena itu, model hanya perlu memiliki korpus/kamus yang banyak akan kata-kata kebencian supaya bisa berkinerja baik. Di sinilah letak keunggulan IndoBERT. Model ini dilatih pada korpus data Indo4B yang sangat besar dan beragam, mencakup berita, forum online, artikel, dan juga media sosial. Keragaman ini kemungkinan besar telah membuat IndoBERT mengenali variasi bahasa agresif dan kasar yang lebih luas, tidak hanya dari satu platform saja.

Di sisi lain, IndoBERTweet, meskipun dilatih dalam bahasa Twitter, mungkin memiliki spesialisasi yang terlalu sempit untuk tugas ini. Ia sangat baik dalam mengenali slang percakapan dan singkatan khas Twitter, namun ciri khas bahasa kebencian yang ada di dalam dataset ini mungkin tidak sepenuhnya terwakili dalam data pelatihannya. Bisa jadi, kata-kata kasar yang digunakan dalam dataset sering ditemukan pada kolom komentar berita atau forum (yang menjadi bagian dari data pelatihan IndoBERT) daripada di Twitter. Akibatnya, korpus milik IndoBERT bisa lebih lengkap dan relevan untuk dataset ini.

Temuan ini menunjukkan bahwa untuk tugas yang sangat bergantung pada pengenalan kosakata spesifik seperti deteksi ujaran kebencian, model dengan fondasi pemahaman bahasa yang lebih luas dan beragam (IndoBERT) dapat terbukti lebih baik. Spesialisasi pada satu domain (seperti yang dimiliki IndoBERTweet) tidak selalu menjamin keunggulan jika kosakata kunci dari tugas tersebut tidak terwakili dengan baik dalam data spesialisasinya.

c. Perbandingan Kedua Dataset dan Kesimpulan Model Terbaik

Perbandingan antara dataset Sarkasme dan Ujaran Kebencian menjelaskan bagaimana karakteristik dataset secara dasar memengaruhi perilaku dan performa model. Hasil dari proyek ini menemukan perbedaan mendasar antara sarkasme sebagai teks



yang sangat bergantung pada konteks, sementara ujaran kebencian lebih bergantung pada kosakata. Perbedaan inilah yang menjelaskan mengapa strategi pemodelan yang sama dapat memberikan hasil yang sangat berbeda di kedua dataset.

Bukti terkuat dapat terlihat pada eksperimen freeze layers. Pada dataset Sarkasme, membekukan layer IndoBERT justru meningkatkan performa, menandakan bahwa sarcasm ini lebih membutuhkan penyesuaian pada layer-layer akhir yang lebih abstrak dan kontekstual. Sebaliknya, pada dataset Ujaran Kebencian, cara yang sama justru menurunkan performa kedua model secara signifikan. Ini menunjukkan bahwa tugas deteksi ujaran kebencian sangat bergantung pada pemahaman leksikal (kata-kata kunci) yang dipelajari di layer-layer awal. Ketika layer itu dibekukan, maka akan mengurangi kemampuan model untuk mendeteksi fitur-fitur penting tersebut.

Dari seluruh eksperimen, IndoBERT secara konsisten menunjukkan performa yang lebih unggul daripada IndoBERTweet pada kedua dataset. Pada sarkasme, fondasi pemahaman bahasa yang lebih luas dan beragam dari korpus Indo4B memungkinkan IndoBERT untuk lebih pintar mendeteksi pergeseran makna dan konteks. Sementara pada tugas ujaran kebencian, keragaman data latih yang sama kemungkinan besar telah memberikan kamus kata-kata kasar dan agresif yang lebih luas. Temuan ini akhirnya dapat mengarah pada kesimpulan akhir yang penting: untuk tugas-tugas klasifikasi teks informal dalam Bahasa Indonesia, model "generalis" dengan fondasi data pre-training yang masif dan beragam (IndoBERT) dapat terbukti lebih robust dan berkinerja lebih baik daripada model "spesialis" yang dilatih pada domain yang lebih sempit (IndoBERTweet).

7. Kesimpulan

Proyek ini dilakukan untuk membandingkan kinerja dua model Transformer Bahasa Indonesia, IndoBERT dan IndoBERTweet, pada dua



tugas klasifikasi teks yang memiliki karakteristik berbeda: deteksi sarkasme (yang sangat bergantung pada konteks) dan deteksi ujaran kebencian (yang lebih bergantung pada kosakata). Eksperimen juga menganalisis dampak dari berbagai strategi preprocessing dan teknik freeze layer. Berdasarkan serangkaian eksperimen yang telah dijalankan, tujuan proyek ini telah berhasil tercapai dengan menghasilkan beberapa temuan kunci yang memberikan wawasan mendalam mengenai perilaku model-model ini.

Secara keseluruhan, model yang menunjukkan performa terbaik dan paling konsisten di kedua dataset adalah IndoBERT (indobenchmark/indobert-base-pl). Pada dataset sarkasme, IndoBERT unggul karena memiliki fondasi pemahaman bahasa yang lebih luas dari data latihnya yang beragam, memungkinkannya lebih sensitif terhadap pergeseran makna dan konteks yang menjadi inti dari sarkasme. Namun, performa puncaknya untuk sarcasm ini justru diraih saat menggunakan teknik freeze layer, yang mengindikasikan bahwa metode ini efektif sebagai regularisasi untuk mencegah overfitting. Pada dataset ujaran kebencian, keunggulan IndoBERT juga terlihat jelas, kemungkinan besar karena kamus kata yang lebih kaya akan variasi kata-kata kasar dan agresif yang dipelajari dari berbagai sumber data, tidak hanya dari satu platform media sosial saja.

Temuan dari hasil proyek ini bisa menjadi kontribusi menarik bagi perkembangan NLP di Indonesia. Pertama, proyek ini membuktikan bahwa tidak ada satu model terbaik untuk semua jenis teks informal. Pemilihan model tidak bisa hanya didasarkan pada nama atau domain umumnya (misalnya, IndoBERTweet untuk semua teks media sosial), tapi juga harus mempertimbangkan sifat dari kasus itu sendiri, apakah lebih membutuhkan pemahaman konteks yang dalam atau pengenalan kosakata spesifik. Kedua, ditemukan bahwa strategi preprocessing seperti mempertahankan stopwords justru sangat bermanfaat untuk tugas yang bergantung pada nada seperti sarkasme. Terakhir, proyek ini mementingkan analisis kritis terhadap hasil. Performa model sangat bergantung pada kualitas dan



karakteristik dataset, dan temuan seperti keunggulan kedua model menunjukkan bahwa fondasi pemahaman bahasa yang luas tetap menjadi aset yang sangat berharga dalam menghadapi keragaman tantangan NLP.

8. Future Works

- Penyempurnaan Dataset Sarkasme: Membuat dataset sarkasme baru yang menyertakan konteks percakapan (misalnya, komentar induk yang direspons) untuk setiap sampel data, karena analisis menunjukkan bahwa sarkasme sangat bergantung pada konteks.
- Augmentasi Data Kelas Minoritas: Menerapkan teknik augmentasi data seperti back-translation atau parafrase secara spesifik pada data sarkasme untuk mengatasi masalah ketidakseimbangan kelas dan meningkatkan skor MCC model.
- Eksperimen dengan Model yang Lebih Besar: Menguji performa versi large dari model yang ada (misalnya, indobenchmark/indobert-large-p2) untuk melihat apakah peningkatan jumlah parameter dapat menangkap nuansa sarkasme yang lebih kompleks.
- Analisis Lintas Domain yang Lebih Dalam: Menguji model terbaik (IndoBERT) pada domain teks informal lainnya (misalnya, komentar YouTube atau Facebook) untuk memvalidasi apakah keunggulannya bersifat general di berbagai platform.
- Integrasi ke Sistem Aplikasi: Membangun purwarupa sistem nyata, seperti REST API atau browser extension, dari model terbaik untuk mendeteksi potensi sentimen negatif terselubung atau ujaran kebencian secara real-time di platform digital.

9. Output

Tuliskan link akhir project kalian, misal:

- Notebook: <https://github.com/huseinsm/IS-Kelompok-3.git>



DIKTISAINTEK
BERDAMPAK

- Model terbaik: [file .h5/.pt/.onnx] → menyusul dalam bentuk link drive karena ukurannya besar.

- Slide presentasi:

https://www.canva.com/design/DAG12mHMEOs/SKjvNyKcuYL4I1bvmCElig/view?utm_content=DAG12mHMEOs&utm_campaign=designshare&utm_medium=link2&utm_source=uniquelinks&utlId=h3a1d257fla



INTELLIGENT SYSTEM LABORATORY

@is.lab.filkom