

Analisis Komparatif Model IndoBERT dan IndoBERTweet untuk Klasifikasi *Hatespeech* dan Sarkasme pada Teks bahasa Indonesia

Oleh:

1. Husein Sidharta Muhammad - 245150707111040
2. Jose Putra Perdana Taneo - 235150200111047

Latar Belakang

- Di era modern, etika tidak terbatas pada dunia nyata, tetapi juga dunia maya
- Peringkat Sopan santun netizen Indonesia masih sangat rendah .
- Sarkasme merupakan sesuatu yang tricky karena mungkin memiliki nada yang berlawanan

Latar Belakang

- Artificial Intelligence sedang dalam akselerasi yang kuat
- Deep Learning menawarkan kemampuan yang robust dengan mekanisme Loss Calculation, Backpropagation, hingga Iterasi

Latar Belakang

IndoBERT dan IndoBERTweet
adalah model yang terbukti
robust.

IndoBERT

- Data pretrain: Indonesian Wikipedia, news articles, dan Common Crawl dengan ± 220 juta kata.
- Bagus dalam gaya bahasa yang luas, tetapi utamanya formal

IndoBERTtweet

- Data pretrain: 26 juta tweet dengan ± 380 juta token
- Bagus dalam gaya bahasa informal.

Rumusan Masalah

1. Bagaimana perbandingan akurasi kedua model pada deteksi hatespeech bahasa Indonesia?
2. Bagaimana perbandingan akurasi kedua model pada deteksi sarkasme bahasa Indonesia?
3. Mengapa sebuah model lebih baik dari model yang lain?

Metode



FULL FINE-TUNING

Layer model dan weights disesuaikan ulang keseluruhan dengan dataset yang spesifik.

PARTIAL FINE-TUNING (FREEZE 7 LAYER)

Membekukan 7 layer awal agar fokus pada penyesuaian lapisan atas dan klasifikasi.

Train-test split

Dataset hatespeech (train, test, val): 80/10/10

Dataset sarcasm (train, test, val): 70/20/10

Metode

● PARAMETER HATESPEECH

- training batch size = 32
- val batch size = 16
- learning rate = $2e-5$
- epoch = 3
- Optimizer = AdamW
- Loss Function = CrossEntropyLoss
- Weight Decay (membatasi besar bobot untuk mencegah overfit) = 0.01

● PARAMETER SARCASM

- training batch size = 16
- val batch size = 16
- learning rate = $2e-5$
- epoch = 3
- Optimizer = AdamW
- Loss Function = CrossEntropyLoss
- Weight Decay (membatasi besar bobot untuk mencegah overfit) = 0.01


Dataset

● HATESPEECH

Sumber:

[https://huggingface.co/datasets/nahiar/hate_speech_detection/tree/main?](https://huggingface.co/datasets/nahiar/hate_speech_detection/tree/main?utm_source=chatgpt.com)
[utm_source=chatgpt.com](https://huggingface.co/datasets/nahiar/hate_speech_detection/tree/main?utm_source=chatgpt.com)

Jumlah data: 1300




Dataset

● SARKASME

Sumber:

https://huggingface.co/datasets/w1lwo/reddit_indonesia_sarcastic

Jumlah data: 14116



Hasil & Pembahasan

HATESPEECH DETECTION

A. IndoBERT full fine-tune

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.279000	0.292748	0.871203	0.824161	0.883453	0.852778
2	0.157100	0.284253	0.893682	0.896341	0.846043	0.870466
3	0.078400	0.371614	0.892467	0.871060	0.874820	0.872936

Menunjukkan progress akurasi yang konsisten. Setelah epoch ke-2 akurasi turun (mulai stack).


Hasil & Pembahasan

HATESPEECH DETECTION

A. IndoBERT full fine-tune

- Confusion matrix data test

Memperoleh akurasi 90,16%, dimana sebaran False Positif dan False Negatif relatif merata (79 dan 83)




Hasil & Pembahasan

HATESPEECH DETECTION

A. IndoBERT full fine-tune

- Classification report

Munjukkan performa yang sangat baik, dengan akurasi 90,16% dan F1-Score 0,88, menandakan keseimbangan antara presisi dan recall. Nilai loss 0,39 menunjukkan error yang relatif rendah.



Hasil & Pembahasan

HATESPEECH DETECTION

B. IndoBERTweet full fine-tune

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.489600	0.483134	0.772783	0.698885	0.811511	0.750999
2	0.392300	0.447298	0.808019	0.846435	0.666187	0.745572
3	0.263100	0.437543	0.823815	0.839196	0.720863	0.775542

Epoch pertama berada pada 77% dan menunjukkan progress akurasi yang konsisten. Puncak akurasi selama train 82,38%.


Hasil & Pembahasan

HATESPEECH DETECTION

B. IndoBERTweet full fine-tune

- Confusion matrix data test

Memperoleh akurasi 82,33%, dimana sebaran False Positif dan False Negatif relatif lebih dominan False Negatif (106:185)




Hasil & Pembahasan

HATESPEECH DETECTION

B. IndoBERTTweet full fine-tune

- Classification report

Model menunjukkan performa yang cukup solid, dengan akurasi 82,33% dan F1-Score 0,78, yang mencerminkan kemampuan model dalam menyeimbangkan presisi (0,83) dan recall (0,73). Nilai loss 0,43 mengindikasikan masih terdapat ruang untuk peningkatan



Hasil & Pembahasan

HATESPEECH DETECTION

C. IndoBERT partial fine-tune (freeze 7 layer pertama)

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.398900	0.334014	0.860267	0.793190	0.905036	0.845430
2	0.257800	0.329224	0.888214	0.867626	0.867626	0.867626
3	0.193700	0.360728	0.891252	0.869628	0.873381	0.871500

Epoch pertama menyentuh 86% dan menunjukkan progress akurasi yang konsisten. Puncak akurasi selama train 89,12%.


Hasil & Pembahasan

HATESPEECH DETECTION

C. IndoBERT partial fine-tune (freeze 7 layer pertama)

- Confusion matrix data test

Memperoleh akurasi 88,1%, dimana sebaran False Positif dan False Negatif relatif merata (99 dan 97)




Hasil & Pembahasan

HATESPEECH DETECTION

C. IndoBERT partial fine-tune (freeze 7 layer pertama)

- Classification report

Model menunjukkan performa yang baik, dengan akurasi 88,10% dan F1-Score 0,86, yang menandakan keseimbangan yang stabil antara presisi (0,86) dan recall (0,86). Nilai loss 0,37 menunjukkan tingkat kesalahan yang relatif rendah



Hasil & Pembahasan

HATESPEECH DETECTION

D. IndoBERTweet partial fine-tune (freeze 7 layer pertama)

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	F1
1	0.644400	0.547152	0.715067	0.652335
2	0.539500	0.512984	0.756987	0.686028
3	0.471600	0.503978	0.774605	0.717010

Epoch pertama berada di akurasi 71,5% dan menunjukkan progress akurasi yang konsisten. Puncak akurasi selama train 77,4%.


Hasil & Pembahasan

HATESPEECH DETECTION

D. IndoBERTTweet partial fine-tune (freeze 7 layer pertama)

- Confusion matrix data test

Memperoleh akurasi 77,35%, dimana sebaran False Non-HS mendominasi False HS (229:144)




Hasil & Pembahasan

HATESPEECH DETECTION

D. IndoBERTweet partial fine-tune (freeze 7 layer pertama)

- Classification report

menunjukkan performa yang cukup moderat, dengan akurasi 77,35% dan F1-Score 0,71, yang menandakan kemampuan model dalam mengenali pola masih perlu ditingkatkan. Nilai loss 0,48 menunjukkan tingkat kesalahan yang relatif lebih tinggi dibanding model sebelumnya



Uji 10 epoch

● **INDOBERT** Memuncak di 89%

● **INDOBERTWEET** Memuncak di 84%

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.282800	0.322647	0.855407	0.780368	0.915108	0.842384
2	0.169200	0.285344	0.889429	0.880000	0.854676	0.867153
3	0.108600	0.417703	0.890036	0.874636	0.863309	0.868936
4	0.059200	0.492800	0.888214	0.865522	0.870504	0.868006
5	0.022900	0.591020	0.894289	0.871612	0.879137	0.875358
6	0.030000	0.690594	0.889429	0.907790	0.821583	0.862538
7	0.015400	0.690315	0.891859	0.861538	0.886331	0.873759
8	0.012100	0.688425	0.891859	0.889894	0.848921	0.868925
9	0.007800	0.725293	0.891252	0.881657	0.857554	0.869438
10	0.003200	0.728876	0.892467	0.882006	0.860432	0.871085

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.511700	0.485327	0.767315	0.798851	0.600000	0.685292
2	0.389900	0.438181	0.813487	0.851449	0.676259	0.753809
3	0.333200	0.416159	0.829283	0.800872	0.792806	0.796819
4	0.259900	0.461441	0.835966	0.841091	0.753957	0.795144
5	0.198100	0.442006	0.840826	0.809728	0.814388	0.812052
6	0.152700	0.489225	0.845079	0.840557	0.781295	0.809843
7	0.139200	0.578360	0.845079	0.821637	0.808633	0.815083
8	0.074600	0.672809	0.832321	0.788171	0.824460	0.805907
9	0.093800	0.723074	0.845079	0.858306	0.758273	0.805195
10	0.051400	0.731108	0.842041	0.833078	0.782734	0.807122

IndoBERT mengungguli IndoBERTweet, dimana IndoBERT juga memiliki kesalahan sebaran kelas yang merata

Eksperimen preprocessing SARKASME

● INDOBERT Memperoleh di 80%

Tabel Perbandingan Hasil Eksperimen Awal (diukur pakai set validasi):

	eval_f1	eval_mcc	eval_accuracy	eval_loss
text_nosw_norm	0.792859	0.435777	0.800142	0.447028
text_nosw_nonorm	0.790940	0.431359	0.797307	0.446295
text_sw_norm	0.776252	0.391714	0.782424	0.474224
text_sw_nonorm	0.775832	0.391949	0.781006	0.476622

Preprocessing Terbaik: 'text_nosw_norm'

IndoBERT dapat maksimal saat dibiarkan memiliki stopwords tetapi dilakukan normalisasi kata

Eksperimen preprocessing SARKASME

● INDOBERTWEET Memperoleh di 81%

Tabel Perbandingan Hasil Eksperimen Awal (diukur pakai set validasi):

	eval_f1	eval_mcc	eval_accuracy	eval_loss
text_nosw_nonorm	0.811236	0.487697	0.816442	0.447360
text_nosw_norm	0.804703	0.472597	0.807938	0.418253
text_sw_norm	0.786952	0.421669	0.792346	0.450993
text_sw_nonorm	0.783028	0.409723	0.789511	0.449463

Preprocessing Terbaik: 'text_nosw_nonorm'

IndoBERTTweet dapat maksimal saat dibiarkan memiliki stopwords tetapi dilakukan normalisasi kata

Hasil & Pembahasan

SARKASME DETECTION

A. IndoBERT full fine-tune

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	F1	Precision	Recall	Mcc
1	0.424200	0.432466	0.793055	0.772756	0.775385	0.793055	0.380225
2	0.306700	0.447028	0.800142	0.792859	0.789781	0.800142	0.435777
3	0.150600	0.555415	0.790928	0.785744	0.782585	0.790928	0.418682

Menunjukkan progress akurasi yang fluktuatif. Setelah epoch ke-2 akurasi turun.


Hasil & Pembahasan

SARKASME DETECTION

A. IndoBERT full fine-tune

- Confusion matrix data test

Memperoleh akurasi 80%, dimana perbandingan kebenaran dan kesalahan pada data label Sarkastik (390:316)



Hasil & Pembahasan

SARKASME DETECTION

A. IndoBERT full fine-tune

- Classification report

Meskipun performa pada non-sarkastik cukup baik, model masih kesulitan mendeteksi sarkasme secara konsisten (recall 0,55). Nilai MCC = 0,45 menandakan kemampuan model sedang

Laporan Klasifikasi Indobert (text_nosw_norm) di Test Set:

	precision	recall	f1-score	support
Non-Sarkastik	0.86	0.88	0.87	2118
Sarkastik	0.61	0.55	0.58	706
accuracy			0.80	2824
macro avg	0.73	0.72	0.73	2824
weighted avg	0.79	0.80	0.80	2824
Matthews Correlation Coefficient (MCC) Final: 0.4515				

Hasil & Pembahasan

SARKASME DETECTION

B. IndoBERTweet full fine-tune

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	F1	Precision	Recall	Mcc
1	0.410600	0.410466	0.802977	0.792321	0.790233	0.802977	0.432827
2	0.330500	0.418322	0.806520	0.805101	0.803890	0.806520	0.477089
3	0.253700	0.447360	0.816442	0.811236	0.808820	0.816442	0.487697

Menunjukkan progress akurasi yang tidak signifikan. Dari 80,29% akurasi maksimal di 81,64%


Hasil & Pembahasan

SARKASME DETECTION

B. IndoBERTweet full fine-tune

- Confusion matrix data test

Memperoleh akurasi 81%, dimana perbandingan kebenaran dan kesalahan pada data label Sarkastik (367:339)



Hasil & Pembahasan

SARKASME DETECTION

B. IndoBERTweet full fine-tune

- Classification report

performa pada non-sarkastik cukup andal, tetapi model masih memiliki recall sebesar 0,52 pada sarkastik. Nilai MCC = 0,45 menandakan kemampuan model sedang

HASIL AKHIR DI TEST SET

Laporan Klasifikasi Indobertweet (text_nosw_nonorm) di Test Set:

	precision	recall	f1-score	support
Non-Sarkastik	0.85	0.90	0.87	2118
Sarkastik	0.63	0.52	0.57	706
accuracy			0.81	2824
macro avg	0.74	0.71	0.72	2824
weighted avg	0.80	0.81	0.80	2824

Matthews Correlation Coefficient (MCC) Final: 0.4510

Hasil & Pembahasan

SARKASME DETECTION

C. IndoBERT partial fine-tune

- Progress training

[927/927 06:45, Epoch 3/3]

Epoch	Training Loss	Validation Loss	Accuracy	F1	Precision	Recall	Mcc
1	0.424800	0.447381	0.793763	0.766781	0.777035	0.793763	0.370607
2	0.363200	0.428224	0.800850	0.794717	0.791688	0.800850	0.441875
3	0.297300	0.441495	0.796598	0.786320	0.783488	0.796598	0.416074

Menunjukkan progress akurasi yang fluktuatif. Sempat akurasi 80%, tetapi turun ke 79%.


Hasil & Pembahasan

SARKASME DETECTION

C. IndoBERT partial fine-tune

- Confusion matrix data test

Memperoleh akurasi 81%, dimana perbandingan kebenaran dan kesalahan pada data label Sarkastik (374:332)



Hasil & Pembahasan

SARKASME DETECTION

C. IndoBERT partial fine-tune

- Classification report

Memberikan hasil yang mirip, model memiliki Recall 0,53 (sedikit lebih tinggi) pada sarkastik. Nilai MCC = 0,4692 juga memperlihatkan keunggulan model dari yang sebelumnya.

Laporan Klasifikasi di Test Set:

	precision	recall	f1-score	support
Non-Sarkastik	0.85	0.91	0.88	2118
Sarkastik	0.65	0.53	0.58	706
accuracy			0.81	2824
macro avg	0.75	0.72	0.73	2824
weighted avg	0.80	0.81	0.81	2824

Matthews Correlation Coefficient (MCC): 0.4692

Hasil & Pembahasan

SARKASME DETECTION

D. IndoBERTweet partial fine-tune

- Progress training

Epoch	Training Loss	Validation Loss	Accuracy	F1	Precision	Recall	Mcc
1	0.419400	0.419412	0.801559	0.797665	0.795121	0.801559	0.452655
2	0.376400	0.418473	0.795889	0.795696	0.795506	0.795889	0.454936
3	0.330300	0.421712	0.806520	0.798844	0.796164	0.806520	0.451951

Tidak menunjukkan progress akurasi yang baik, stuck pada 80%.

Hasil & Pembahasan

SARKASME DETECTION

D. IndoBERTweet partial fine-tune

- Confusion matrix data test

Memperoleh akurasi 80%, dimana perbandingan kebenaran dan kesalahan pada data label Sarkastik (340:366)



Hasil & Pembahasan

SARKASME DETECTION

D. IndoBERTweet partial fine-tune

- Classification report

Memberikan hasil yang lebih rendah dari sebelumnya (akurasi 80% dan recall sarkastik 0.48). Begitu juga MCC = 0,5263.

Laporan Klasifikasi di Test Set:

	precision	recall	f1-score	support
Non-Sarkastik	0.84	0.91	0.87	2118
Sarkastik	0.63	0.48	0.55	706
accuracy			0.80	2824
macro avg	0.73	0.69	0.71	2824
weighted avg	0.79	0.80	0.79	2824

Matthews Correlation Coefficient (MCC): 0.4263

Hasil SARKASME

● INDOBERT

IndoBERT mengungguli IndoBERTweet dengan detail: dilakukan freeze 7 layer untuk mengkombinasi bobot pretrain.


Recall: 0,53

Nilai MCC = 0,4692

Kesimpulan

1. IndoBERT full fine-tune memperoleh akurasi tertinggi sebesar 90,16% pada deteksi hatespeech.
2. IndoBERT partial fine-tune (normalisasi kata dan mempertahankan stop-word) memperoleh akurasi tertinggi sebesar 81% pada deteksi sarkasme.
3. IndoBERT dapat mengungguli IndoBERTweet karena lebih robust terhadap noise linguistik, dilatih dengan korpus besar dan bersih yang memberikan representasi semantik yang luas dan stabil terhadap akar kata, struktur gramatikal, dan pola sintaksis baku.

Daftar Pustaka



Kompas.com. (2022, Maret 26). Penyebab netizen Indonesia disebut paling tidak sopan se-Asia Tenggara. Kompas. <https://www.kompas.com/wiken/read/2022/03/26/110500081/penyebab-netizen-indonesia-disebut-paling-tidak-sopan-se-asia-tenggara?page=all>

Kementerian Komunikasi dan Informatika Republik Indonesia. (2022). Dampak perundungan siber terhadap kesehatan mental remaja. Kominfo.go.id. https://www.kominfo.go.id/content/detail/41415/dampak-perundungan-siber-terhadap-kesehatan-mental-remaja/0/artikel_gpr

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., ... & Purwarianti, A. (2020). IndoBERT: A pretrained language model for Indonesian. Findings of EMNLP 2020, 1235–1241.

Koto, F., Lau, J. H., & Baldwin, T. (2021). IndoBERTweet: A pretrained language model for Indonesian Twitter with effective domain adaptation. Findings of EMNLP 2021, 2226–2231.



INTELLIGENT SYSTEM
LABORATORY



Thank You!